Inteligência Artificial

Q-Learning Aproximado em um Labirinto com Armadilhas

Caroline Nunes Araujo
Gabriel Ciriaco de Carvalho
João Gabriel de Morais Bezerra

Professor: Danillo Roberto Pereira

Outubro de 2026

Sumário

1 Introdução e Objetivo **2**

2 Descrição do Ambiente **2**

2.1 Mapa e Estado do Agente 2

2.2 Ações e Recompensas 3

2.3 Encerramento dos Episódios 3

3 Q-Learning com Aproximação Linear **4**

3.1 Estimativa do Valor das Ações 4

3.2 Características Utilizadas 4

3.2.1 Distância Normalizada 4

3.2.2 Bases Gaussianas 5

3.3 Escolha das Ações 5

3.4 Atualização dos Pesos 5

3.5 Avaliação do Agente 6

4 Configuração dos Experimentos **6**

5 Resultados e Discussão **7**

5.1 Influência da Taxa de Aprendizado 7

5.2 Influência da Quantidade de Episódios 9

5.3 Percurso do Modelo Ilustrado 10

5.4 Variação entre as Sementes 11

6 Conclusão e Limitações **11**

1 Introdução e Objetivo

O aprendizado por reforço permite que um agente aprenda a escolher ações a partir de suas interações com um ambiente. Após executar uma ação, o agente observa suas consequências e recebe uma recompensa, utilizada para ajustar suas estimativas e orientar decisões futuras.

Neste trabalho, foi implementado um jogo de labirinto com paredes, caminhos alternativos e armadilhas. O agente deve alcançar a saída, considerando as penalidades recebidas durante o percurso.

O objetivo é implementar o Q-learning com aproximação linear para aprender a jogar esse ambiente e analisar a influência da taxa de aprendizado e da quantidade de episódios no desempenho obtido.

2 Descrição do Ambiente

2.1 Mapa e Estado do Agente

O ambiente utiliza um mapa fixo de sete linhas e nove colunas. O estado é representado pela posição do agente no formato (linha, coluna), com índices iniciados em zero.

O agente começa na posição $(1, 1)$ e deve alcançar a saída em $(1, 7)$. As armadilhas estão nas posições $(2, 4)$ e $(5, 5)$. O mapa permanece inalterado durante o treinamento e a avaliação.

Tabela 1: Símbolos utilizados no mapa.

Símbolo	Significado
`#`	Parede
`.`	Caminho livre
`S`	Posição inicial
`E`	Saída
`T`	Armadilha

A disposição das células é apresentada a seguir:

```
# # # # # # # # #
# S . . . # . E #
# . # # T # . # #
# . # . . . . # #
# . # . # # . # #
# . . . # T . . #
# # # # # # # # #
```

2.2 Ações e Recompensas

As ações disponíveis são mover para cima, baixo, esquerda ou direita, uma célula por movimento. Tentativas de atravessar paredes ou ultrapassar os limites da matriz mantêm o agente na posição atual.

Tabela 2: Recompensas definidas para as ações.

Resultado da ação	Recompensa
Movimento para caminho livre ou posição inicial	-1
Tentativa de atravessar parede ou limite do mapa	-3
Entrada em armadilha	-10
Chegada à saída	$+30$

Cada ação recebe apenas uma das recompensas indicadas. Ao entrar em uma armadilha, o agente avança para essa célula, recebe a penalidade e continua o episódio. A armadilha permanece no mapa após sua passagem.

A penalidade por movimento incentiva percursos menores, enquanto a penalidade das armadilhas cria uma escolha entre caminhos mais curtos e caminhos que evitam esses custos.

2.3 Encerramento dos Episódios

Cada episódio começa na posição inicial e termina quando o agente alcança a saída ou completa 150 movimentos, incluindo colisões. Atingir o limite encerra a tentativa sem sucesso.

No treinamento, esse limite é tratado como uma interrupção externa: apenas a chegada à saída zera o valor futuro na atualização dos pesos. Atingir o limite não recebe uma penalidade terminal adicional.

3 Q-Learning com Aproximação Linear

3.1 Estimativa do Valor das Ações

Diferentemente do Q-learning tabular, que armazena valores independentes para pares de estado e ação, a implementação utiliza uma função para estimar esses valores:

$$\widehat{Q}(s,a) = \sum_{i=1}^{17} w_i f_i(s,a) = \mathbf{w}^\mathsf{T}\mathbf{f}(s,a).$$

As funções f_i representam as características da posição e da ação, e os pesos w_i são ajustados durante o aprendizado. Todos os 17 pesos são inicializados com zero no início de cada treinamento e preservados entre seus episódios.

3.2 Características Utilizadas

A posição resultante corresponde à célula em que o agente ficaria após realizar uma ação. Em caso de colisão, ela permanece igual à posição atual.

Tabela 3: Características utilizadas na aproximação de Q.

Característica	Descrição
Bias	Constante igual a 1, permitindo aprender um valor básico para Q.
Colisão	Vale 1 se a ação tentar atravessar uma parede ou sair do mapa; caso contrário, vale 0.
Armadilha	Vale 1 se a ação entrar em uma armadilha; caso contrário, vale 0.
Saída	Vale 1 se a ação alcançar a saída; caso contrário, vale 0.
Distância normalizada	Distância Manhattan da posição resultante até a saída, dividida por 14.
12 bases gaussianas	Representam a proximidade da posição resultante a pontos de referência distribuídos pelo mapa.

3.2.1 Distância Normalizada

A distância Manhattan é calculada por:

$$d = |\text{linha} - \text{linha}_{\text{saída}}| + |\text{coluna} - \text{coluna}_{\text{saída}}|.$$

A normalização utiliza a maior distância Manhattan possível entre duas células da

matriz:

$$d_{\text{normalizada}} = \frac{d}{(7-1)+(9-1)} = \frac{d}{14}.$$

3.2.2 Bases Gaussianas

Somente a distância até a saída não distingue suficientemente as regiões do labirinto. Para acrescentar informação de localização, foram utilizadas 12 bases gaussianas.

Os pontos de referência são as combinações das linhas $\{1, 3, 5\}$ com as colunas $\{1, 3, 5, 7\}$. Para cada ponto, calcula-se:

$$f = \exp\left(-\frac{(\text{linha} - \text{linha}_{\text{ref}})^2 + (\text{coluna} - \text{coluna}_{\text{ref}})^2}{4}\right).$$

Quanto mais próxima a posição resultante estiver do ponto de referência, maior será a ativação dessa característica. Os pontos são referências geométricas e podem estar em paredes.

Posições próximas ativam características semelhantes, permitindo compartilhar aprendizado entre elas. As bases não fornecem um caminho pronto: a avaliação das regiões depende dos pesos aprendidos.

A aproximação permanece linear nos pesos, mesmo com características gaussianas.

3.3 Escolha das Ações

Durante o treinamento, utiliza-se a estratégia ϵ-greedy. Com probabilidade ϵ, uma das quatro ações é sorteada. Caso contrário, o agente escolhe uma ação com o maior Q estimado. Empates são resolvidos por sorteio.

Nos experimentos, ϵ foi mantido em 0,3 durante todo o treinamento. Portanto, ações exploratórias continuam ocorrendo mesmo após o agente aprender um percurso.

3.4 Atualização dos Pesos

Após cada movimento, o agente observa a recompensa r e a próxima posição s'. O novo alvo é:

$$y = \begin{cases} r, & \text{se a saída foi alcançada,} \\ r + \gamma \max\limits_{a'} \widehat{Q}(s', a'), & \text{caso contrário.} \end{cases}$$

A diferença entre o novo alvo e a estimativa atual é o erro temporal:

$$\delta = y - \widehat{Q}(s, a).$$

A atualização utiliza a ideia de reduzir uma perda quadrática:

$$L(\mathbf{w}) = \frac{1}{2}\delta^2.$$

Tratando o novo alvo como fixo durante a atualização, a derivada em relação a cada peso é $-\delta f_i(s, a)$. Ao ajustar os pesos na direção oposta ao gradiente, obtém-se:

$$w_i \leftarrow w_i + \alpha\delta f_i(s, a).$$

O parâmetro α controla o tamanho dos ajustes. Valores pequenos produzem mudanças graduais e podem tornar o aprendizado mais lento. Valores elevados podem causar oscilações ou instabilidade. Uma taxa pequena, por si só, não garante convergência, pois o alvo temporal também muda durante o treinamento.

3.5 Avaliação do Agente

Após o treinamento, os pesos finais são avaliados com $\epsilon = 0$, sem novas atualizações. O agente escolhe ações com maior Q estimado, mantendo o sorteio apenas para desempates.

A avaliação começa na posição inicial e termina ao alcançar a saída ou atingir 150 movimentos. São registradas a pontuação acumulada, a quantidade de movimentos, a indicação de sucesso e a lista de posições percorridas.

4 Configuração dos Experimentos

Foram realizados dois conjuntos de comparações, variando um parâmetro por vez.

Tabela 4: Parâmetros comparados nos experimentos.

Comparação	Valores testados	Configuração fixa
Alpha	0,005; 0,01; 0,05	1.000 episódios
Episódios	100; 500; 1.000	Alpha = 0,01

Em todas as configurações, foram mantidos o mapa, as características, as recompensas e os seguintes parâmetros:

- Fator de desconto: $\gamma = 0{,}95$.

- Exploração no treinamento: $\epsilon = 0{,}3$.
- Limite de 150 movimentos por episódio.
- Sementes de treinamento: 42, 43 e 44.

Cada configuração foi treinada separadamente para cada semente, sempre começando com os pesos zerados. Cada modelo foi avaliado uma vez, utilizando um novo gerador aleatório com semente 123 para desempatar ações com o mesmo Q.

A taxa de sucesso corresponde ao percentual dos três modelos treinados que concluíram o labirinto na avaliação.

As médias e os desvios padrão amostrais foram calculados entre as três sementes, incluindo as avaliações sem sucesso. A pontuação apresentada é a soma das recompensas sem desconto. O fator γ participa do aprendizado, mas não dessa soma.

5 Resultados e Discussão

5.1 Influência da Taxa de Aprendizado

A Tabela 5 apresenta os resultados individuais das avaliações após 1.000 episódios.

Tabela 5: Avaliações para diferentes valores de alpha.

Alpha	Semente	Pontuação	Movimentos	Sucesso
0,005	42	−150	150	Não
0,005	43	−150	150	Não
0,005	44	−150	150	Não
0,01	42	17	14	Sim
0,01	43	−150	150	Não
0,01	44	17	14	Sim
0,05	42	17	14	Sim
0,05	43	12	10	Sim
0,05	44	12	10	Sim

Tabela 6: Resumo da comparação de alpha.

		Pontuação		Movimentos	
Alpha	Sucesso	Média	Desvio Padrão	Média	Desvio Padrão
0,005	0%	−150,00	0,00	150,00	0,00
0,01	66,7%	−38,67	96,42	59,33	78,52
0,05	100%	13,67	2,89	11,33	2,31

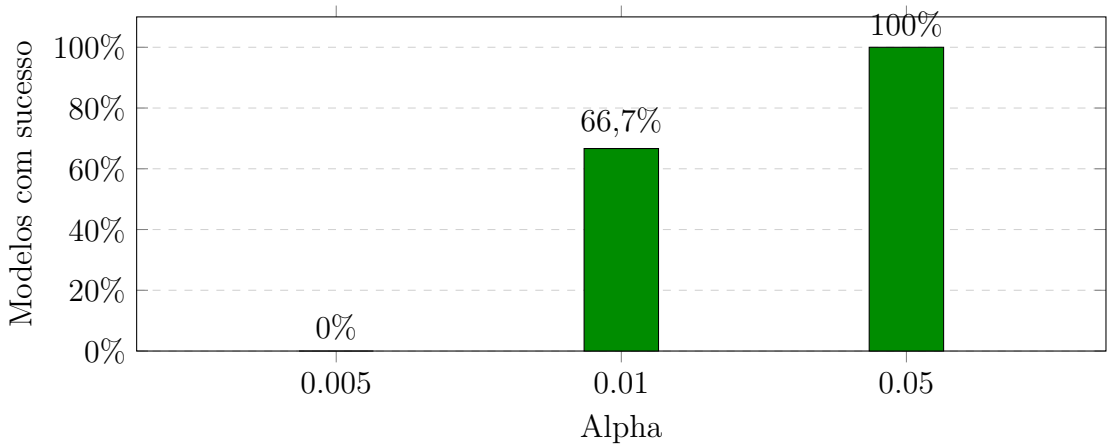


Figura 1: Sucesso por alpha com 1.000 episódios: três sementes e uma avaliação por modelo.

Com $\alpha = 0{,}005$, nenhum dos três modelos alcançou a saída. Todas as avaliações atingiram o limite de movimentos.

Com $\alpha = 0{,}01$, a taxa de sucesso foi de 66,7%, com dois modelos finalizando o labirinto em 14 movimentos e 17 pontos. O modelo da semente 43 não completou o percurso, o que explica a alta variabilidade e os desvios elevados nas métricas de movimentos e pontuação.

Com $\alpha = 0{,}05$, os três modelos alcançaram a saída, mas com resultados diferentes. A semente 42 produziu 14 movimentos e 17 pontos, enquanto as sementes 43 e 44 produziram 10 movimentos e 12 pontos.

Esses resultados mostram que menos movimentos não significa necessariamente maior pontuação, pois o percurso pode envolver penalidades.

Entre as taxas testadas, $\alpha = 0{,}05$ apresentou maior consistência em alcançar a saída.

5.2 Influência da Quantidade de Episódios

A Tabela 7 apresenta os resultados individuais das avaliações para cada quantidade de episódios e semente, mantendo $\alpha = 0{,}01$.

Tabela 7: Avaliações para diferentes quantidades de episódios, com $\alpha = 0{,}01$.

Episódios	Semente	Pontuação	Movimentos	Sucesso
100	42	−150	150	Não
100	43	−150	150	Não
100	44	−150	150	Não
500	42	17	14	Sim
500	43	−150	150	Não
500	44	17	14	Sim
1.000	42	17	14	Sim
1.000	43	−150	150	Não
1.000	44	17	14	Sim

Tabela 8: Resumo da comparação de episódios.

		Pontuação		Movimentos	
Episódios	Sucesso	Média	Desvio Padrão	Média	Desvio Padrão
100	0%	−150,00	0,00	150,00	0,00
500	66,7%	−38,67	96,42	59,33	78,52
1.000	66,7%	−38,67	96,42	59,33	78,52

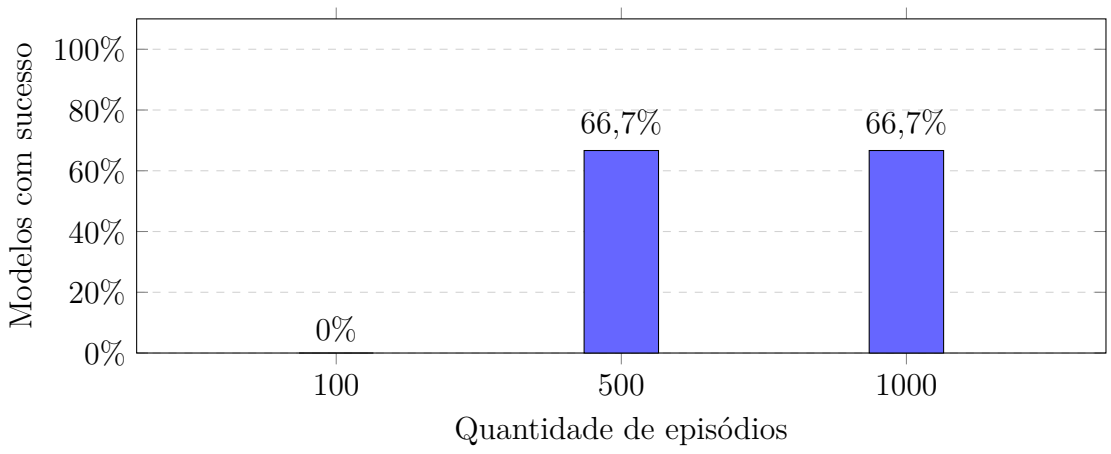


Figura 2: Sucesso por quantidade de episódios com $\alpha = 0{,}01$: três sementes e uma avaliação por modelo.

Com 100 episódios, nenhum modelo alcançou a saída. Por outro lado, tanto com 500 quanto com 1.000 episódios, a taxa de sucesso ficou em 66,7%. Nesses dois cenários, os resultados finais foram idênticos para as três sementes: os modelos das sementes 42 e 44 concluíram o labirinto em 14 movimentos, obtendo 17 pontos, enquanto o modelo da semente 43 permaneceu sem sucesso.

Portanto, aumentar de 100 para 500 episódios melhorou os resultados nas condições testadas. O aumento de 500 para 1.000 não trouxe melhora nos indicadores finais apresentados.

5.3 Percurso do Modelo Ilustrado

Para ilustrar o comportamento aprendido, foi utilizado o modelo treinado com $\alpha = 0{,}01$, 1.000 episódios e semente 42. Sua avaliação alcançou a saída em 14 movimentos, sem entrar em armadilhas e sem colisões.

O percurso foi:

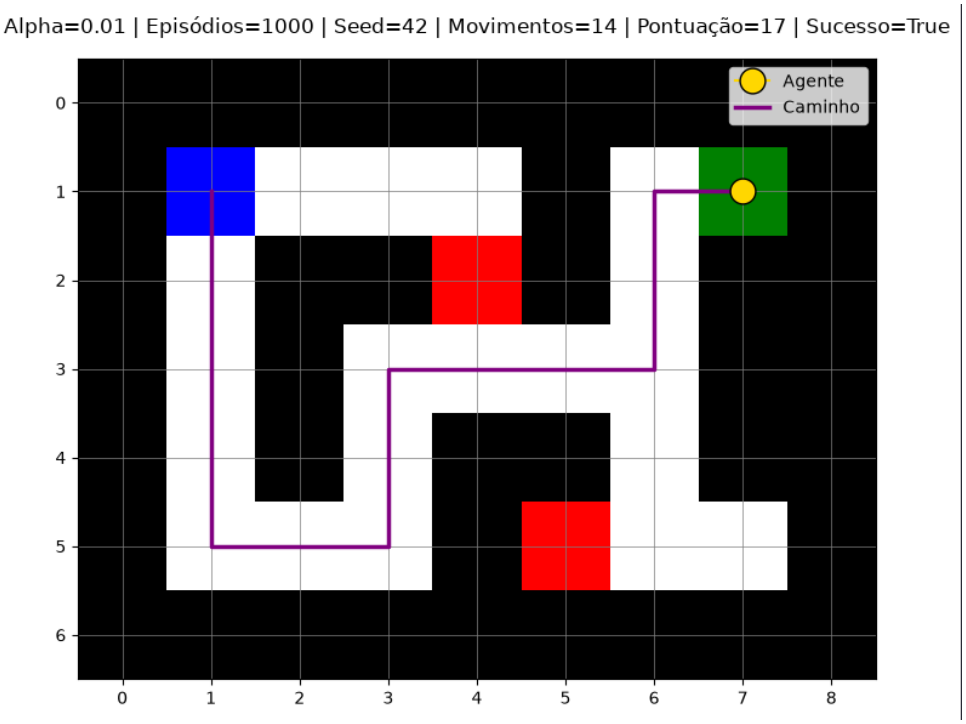


Figura 3: Visualização do percurso percorrido no labirinto.

A pontuação é compatível com 13 movimentos comuns e uma chegada à saída:

$$13(-1) + 30 = 17.$$

5.4 Variação entre as Sementes

Os resultados com $\alpha = 0{,}01$ mostram que a mesma configuração pode produzir desempenhos diferentes conforme a semente. As escolhas exploratórias e os desempates influenciam as experiências utilizadas no aprendizado.

Por esse motivo, a análise inclui tanto os modelos que concluíram o labirinto quanto os que atingiram o limite sem alcançar a saída. O desvio padrão igual a zero indica resultados iguais entre as sementes, mas não significa necessariamente bom desempenho.

6 Conclusão e Limitações

Foi implementado um jogo de labirinto com caminhos alternativos e armadilhas e um agente baseado em Q-learning com aproximação linear. O agente utiliza 17 características e aprende seus pesos a partir das recompensas recebidas durante a interação.

Os experimentos mostraram que a taxa de aprendizado e a quantidade de episódios influenciaram o desempenho nas condições avaliadas. Também foram observadas diferenças entre sementes, indicando que uma execução bem-sucedida não garante o mesmo resultado em todos os treinamentos.

Foi obtido um modelo capaz de alcançar a saída em 14 movimentos, evitando as armadilhas e acumulando 17 pontos. Outros modelos concluíram o jogo com pontuações diferentes ou não alcançaram a saída antes do limite.

Os experimentos foram realizados em um mapa e posição inicial fixos, utilizando três sementes de treinamento e uma avaliação por modelo. As conclusões se restringem às configurações testadas, sem estabelecer garantias de desempenho em outros labirintos, de convergência ou de obtenção da política ótima.